



Institut National de Statistique Et d'Economie Appliquée

Big Data

Préparé par :

- BOUYARMANE Chaimae
- EL AYADI Fatima Ezzahra
- EZZAGRANI Habiba

Sous la direction de :

P. Imade Benelallam

Filière: Master M2SI

Année universitaire :

2023-2024

Table des matières :

Table des matières :	2
Table des figures :	3
I - Introduction :	4
1. Contexte du projet :	4
2. Objectif du projet :	4
3. Méthodologie employée :	5
II - Vision et Mission :	6
1. Vision du projet :	6
2. Mission et objectif à long terme :	6
III - Architecture de l'application :	
IV - Analyse des besoins :	9
1. Data warehouse :	9
2. Description :	9
V - Environnement Technologique et Outils Employés:	10
VI - Implémentation :	12
VII - Résultats et Analyse :	17
1. Insights tirés des données traitées et visualisées :	17
2. Interprétation :	
VIII - Conclusion :	18
1. Récapitulation des objectifs atteints :	18
2. Enseignements tirés et perspectives d'avenir :	
IX- Webographie :	
X- Annexes :	

Table des figures :

Figure 1: Architecture de l'application	7
Figure 2: Data warehouse	9
Figure 3: Docker	13
Figure 4: Les questions	13
Figure 5: Les engagements	14
Figure 6: Cloudera	14
Figure 7: Cloudera manager	15
Figure 8: Data Anonymise	15
Figure 9: Stockage de la data dans HDSF	16
Figure 10: Création des tables dans Hive	16

I - Introduction:

1. Contexte du projet :

Ce projet a pour contexte la nécessité de renforcer la transparence et l'engagement civique dans les activités parlementaires, en particulier au sein de la Chambre des Représentants du Maroc. Historiquement, l'accès aux informations et aux données concernant les questions orales et écrites ainsi que les engagements gouvernementaux a souvent été limité, ce qui a restreint la participation citoyenne et la compréhension globale des actions parlementaires.

Face à cette lacune en matière de transparence, notre projet vise à créer une plateforme basée sur des solutions Big Data qui permettra d'extraire, de traiter, d'analyser et de visualiser les données provenant du site de la Chambre des Représentants du Maroc. En utilisant des outils de pointe tels que la distribution Cloudera QuickStart, Hadoop, HBase, Hive, Jupyter Notebook...

Cette initiative vise à ouvrir l'accès à des informations jusqu'alors peu accessibles, favorisant ainsi une meilleure compréhension des débats parlementaires, des questions posées par les représentants, des réponses gouvernementales et des engagements pris. En élargissant l'accès à ces données, le projet ambitionne de stimuler l'engagement civique en offrant aux citoyens un aperçu détaillé et actualisé des activités parlementaires.

2. Objectif du projet :

L'objectif est de mettre en place une infrastructure technologique robuste et évolutive. Ces objectifs peuvent être définis de la manière suivante :

- 1. Améliorer la Transparence Parlementaire : Offrir un accès accru et transparent aux données relatives aux questions orales, écrites et aux engagements gouvernementaux émanant de la Chambre des Représentants du Maroc.
- **2. Développer une Plateforme Big Data :** Concevoir et mettre en place une plateforme utilisant des technologies Big Data telles que Cloudera QuickStart, Hadoop, HBase, Hive, et Jupyter Notebook pour extraire, traiter, stocker, analyser et visualiser les données parlementaires.

- **3. Faciliter l'Engagement Civique :** Encourager la participation citoyenne en fournissant des informations claires, accessibles et régulièrement mises à jour sur les activités parlementaires. Cela vise à favoriser une compréhension approfondie des débats et des engagements pris par les représentants et le gouvernement.
- **4. Assurer la confidentialité des données :** Mettre en place des protocoles de pseudonymisation pour protéger les données sensibles telles que les noms et les identités des députés, tout en garantissant la confidentialité individuelle.
- **5. Créer des Outils d'Analyse et de Visualisation :** Élaborer des outils et des méthodologies pour analyser les données extraites et les présenter de manière intuitive et compréhensible à travers des visualisations pertinentes.
- **7. Garantir la Fiabilité et la Performance** : Mettre en place des mécanismes de surveillance pour assurer la robustesse, la sécurité et la performance de la plateforme Big Data tout au long de son fonctionnement.

Ces objectifs globaux visent à transformer la manière dont les données parlementaires sont collectées, traitées, analysées et mises à disposition du public, dans le but de renforcer la transparence et l'engagement démocratique au sein de la Chambre des Représentants du Maroc.

3. Méthodologie employée :

La méthodologie utilisée pour ce projet pourrait inclure plusieurs étapes clés :

- 1. Analyse des Besoins et Planification : Cette phase initiale implique la compréhension approfondie des besoins en matière de transparence parlementaire et d'engagement citoyen. Cette analyse détaillée orientera la planification du projet, en identifiant les données pertinentes à extraire et à analyser, ainsi que les outils et technologies nécessaires.
- 2. Conception de l'Architecture de la Plateforme : Élaboration d'une architecture Big Data robuste et évolutive. Cela inclut la définition des différents modules (extraction, stockage, traitement, analyse, visualisation) ainsi que la sélection des outils et technologies adaptés à chaque étape.
- **3. Développement et Implémentation :** Mise en œuvre des composants de la plateforme en suivant les principes de l'architecture définie. Cela peut impliquer

la création de scripts de web scraping pour extraire les données du site parlementaire, l'installation et la configuration des outils de traitement de données (Hadoop, HBase, Hive), la création de workflows pour le traitement des données, etc.

- **4. Sécurité et confidentialité des données :** Intégration de mécanismes de sécurité pour assurer la confidentialité des données sensibles, conformément aux normes et réglementations en vigueur.
- **5. Tests et Validation :** Vérification de la robustesse et de la précision de la plateforme à travers des tests approfondis. Ceci inclut des tests de performance, des tests de fiabilité, ainsi que des vérifications de l'exactitude des données extraites, transformées et analysées.

Cette méthodologie suit un cycle itératif, permettant des ajustements en cours de route pour répondre aux besoins changeants et garantir l'efficacité et la pertinence de la plateforme tout au long du projet.

II - Vision et Mission:

1. Vision du projet :

La vision de notre projet se concentre sur la révolutionner la transparence des activités parlementaires et des interactions, en favorisant un engagement civique accru grâce à des solutions Big Data de pointe. L'objectif est de créer un accès transparent et complet aux données parlementaires, stimulant ainsi la confiance et l'implication citoyenne à travers des outils d'analyse et de visualisation novateurs.

2. Mission et objectif à long terme :

Notre mission consiste à exploiter la puissance des solutions Big Data pour améliorer la transparence parlementaire et l'engagement civique. Nous aspirons à offrir un accès exhaustif aux activités parlementaires tout en préservant la vie privée individuelle. Nos objectifs à long terme incluent la création d'une plateforme robuste et éthique, encourageant l'innovation et l'éducation pour les futurs ingénieurs. Nous visons à instaurer une compréhension approfondie des activités parlementaires et à stimuler la participation citoyenne pour renforcer la démocratie et la confiance dans le processus politique.

III - Architecture de l'application :

L'architecture de l'application pour ce projet est conçue pour répondre à plusieurs besoins cruciaux, allant de l'extraction initiale des données à leur visualisation et à la surveillance continue de la plateforme. Le schéma suivant résume l'architecture de ce projet :

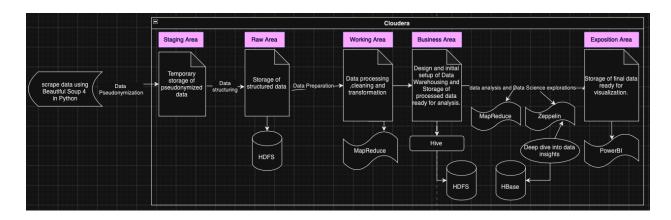


Figure 1: Architecture de l'application

Voici un approfondissement sur chaque point :

- **1. Pseudonymisation Module :** Ce module facultatif vise à protéger la confidentialité des données sensibles, comme les noms et les identités des députés. En utilisant un conteneur Docker, cette étape assure l'anonymisation des informations sensibles tout en conservant l'intégrité des données.
- **2. Data Extraction :** Les scripts de web scraping sont des outils essentiels pour extraire des données à partir des URLs fournies par le site de la Chambre des Représentants du Maroc. Ces scripts sont conçus pour collecter de manière automatisée et efficace les informations pertinentes.

3. Stockage et Modules de Traitement :

- ➤ Espace de Staging : Cette zone permet le stockage temporaire des données brutes juste après leur extraction, avant toute transformation ou traitement ultérieur.
- ➤ **Espace Brut :** Les données sont organisées et stockées dans un format structuré, prêtes à être manipulées pour le traitement.

- ➤ Espace de Travail : Cette zone est dédiée au traitement et à la transformation des données, incluant la préparation, le nettoyage et la normalisation.
- ➤ Espace Business : Une fois les données traitées, elles sont stockées ici, prêtes pour des analyses plus poussées ou des applications spécifiques.
- ➤ **Espace d'Exposition :** Cette section conserve les données finales prêtes à être visualisées, après avoir été préparées et analysées.
- **4. Module d'Ingénierie des Données :** Cette étape implique la préparation, le nettoyage et la transformation des données brutes en données exploitables. Cela inclut le filtrage des données inutiles, la résolution des problèmes de qualité des données et la normalisation des formats.
- **5. Module de Science des Données :** Une fois les données préparées, ce module se concentre sur l'analyse approfondie des données pour extraire des insights significatifs, permettant de comprendre les tendances, les corrélations et les modèles cachés dans les données.
- **6. Entreposage de données :** La création de tables et de schémas dans Hive permet un stockage structuré des données, facilitant ainsi l'accès et l'utilisation ultérieure pour les analyses et les visualisations.
- **7. Module de Visualisation**: Utilisation d'outils de visualisation tels que Tableau, PowerBI, ou tout autre outil pertinent pour présenter de manière visuelle et compréhensible les insights et les conclusions tirés des données.
- **8. Module de Surveillance :** Ce module assure la surveillance proactive de la plateforme, surveillant la santé du système et évaluant les performances des tâches pour détecter et corriger rapidement les éventuelles anomalies.
- **9. Catalogue de données** : Création d'un catalogue de données pour documenter de manière exhaustive les différents ensembles de données disponibles, assurant ainsi une gestion claire et organisée de l'information. Ce catalogue est converti en format YAML pour une meilleure lisibilité et accessibilité.

Ces modules forment un écosystème intégré visant à capturer, traiter, stocker, analyser et présenter les données parlementaires d'une manière qui maximise leur utilité et leur accessibilité pour les utilisateurs finaux.

IV - Analyse des besoins :

1. Data warehouse:

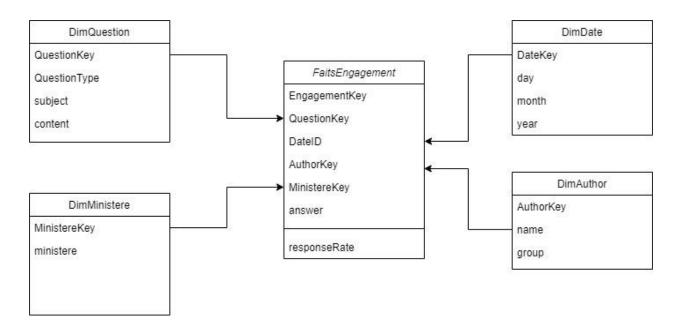


Figure 2: Data warehouse

2. Description:

Notre table de fait est la table d'engagement qui a comme clé étrangère la clé primaire "Key" de toutes les dimensions , et notre KPI est le "responseRate" , c'est-à -dire le taux de réponse ou le taux d'engagement de chaque ministère avec les citoyens . Nos dimensions sont successivement :

- > **DimDate**: La date de la réponse d'après un ministère sur un commentaire.
- > **DimAuthor**: La personne qui a posé le commentaire ainsi qu'avec le groupe où cette personne appartient.
- > DimQuestion : Les différentes questions orales et écrites posées sur les ministères .
- > DimMinistère : Les ministères .

V - Environnement Technologique et Outils Employés:

La mise en œuvre de chaque module du projet s'appuie sur une sélection minutieuse d'outils, de technologies et de frameworks, chacun contribuant de manière spécifique à la réussite du projet. Voici une description détaillée de chaque technologie et outil utilisé :

CLOUDERA Cloudera :Cloudera est une distribution Big Data qui facilite la gestion, le déploiement et la configuration d'outils essentiels tels que Hadoop, Hive et HBase. Fournit une plateforme stable et évolutive pour le traitement des données massives.

Hadoop: Framework open-source permettant le stockage distribué et le traitement parallèle des données sur des clusters de serveurs. Fondement du traitement Big Data, assure la répartition et le traitement efficace des données.

HDFS (Hadoop Distributed File System): Système de fichiers distribué conçu pour stocker de grandes quantités de données de manière fiable qui offre une infrastructure de stockage robuste et scalable pour les données du projet.

Hive: Infrastructure de traitement de données basée sur Hadoop, facilitant l'interrogation et l'analyse de données stockées. Utilisé pour créer des tables et des schémas, permettant le stockage structuré des données.

HBASE :Base de données NoSQL distribuée, orientée colonnes, adaptée au stockage de données semi-structurées et non

structurées.Elle gère efficacement les données non relationnelles, complémentaire à Hive.

Zeppelin :Plateforme de notebook interactive pour l'analyse exploratoire des données. Elle facilite le développement interactif de scripts, particulièrement utile dans le module de Data Science.

PostgreSQL: Système de gestion de base de données relationnelle robuste. Utilisé pour des besoins spécifiques de stockage relationnel et d'exécution de requêtes complexes.

Docker :Plateforme de conteneurisation permettant l'encapsulation d'applications et de dépendances.Utilisé pour isoler et exécuter le module de pseudonymisation dans un environnement contrôlé.

Python: Langage de programmation polyvalent et puissant. Principal langage de développement pour la création de scripts, en particulier dans les modules de web scraping et de transformation des données.

Jupyter: Environnement interactif de développement utilisé pour la création, l'exécution et le partage de notebooks. Facilite le travail interactif et collaboratif dans le module de Data Science.

jupyter

MapReduce : Modèle de programmation pour le traitement distribué de données volumineuses. Utilisé pour les analyses distribuées dans le module MapReduce.

Java: Langage de programmation orienté objet largement utilisé. Utilisé pour le développement d'applications MapReduce et d'autres composants nécessitant une gestion efficace de la mémoire.

VMware est une société informatique américaine fondée en 1998, filiale d'EMC Corporation depuis 2004, qui propose plusieurs produits propriétaires liés à la virtualisation d'architectures x86. C'est aussi par extension le nom d'une gamme de logiciels de virtualisation.

VI - Implémentation :

 Pseudonymisation Module : Ce module facultatif utilise un environnement Docker dédié pour anonymiser les données sensibles, notamment les noms et les identités des députés. L'anonymisation s'opère via des algorithmes spécifiques ou des scripts conçus pour préserver l'intégrité des données tout en masquant les informations sensibles.

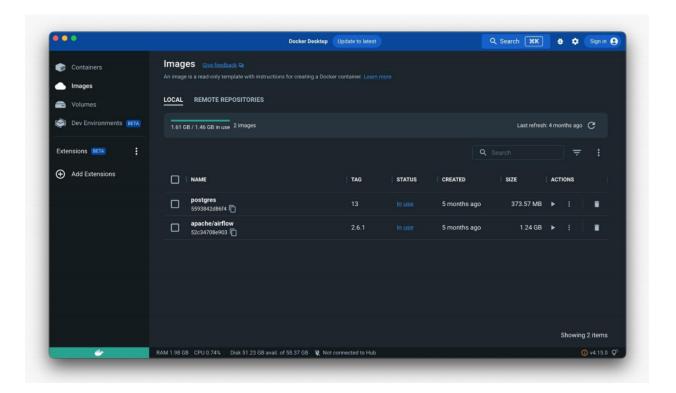


Figure 3: Docker

2. Data Extraction : Pour extraire les données pertinentes du site de la Chambre des Représentants, des scripts de web scraping sur mesure sont mis en place. Ces scripts assurent une collecte automatisée et précise des informations nécessaires en les extrayant des pages web spécifiques.



Figure 4: Les questions

```
▼ 0
    equipe_concernee "none"
    "محمد بادو" representant concerne
    ". إخراج المرسوم المتعلق بالدعم المباشر للسكن بالعالم الحضري والقروي -" reponse
    num_quest "5436"
    "الفريق الاشتراكي" equipe_concernee
    'سعید انمیلی" representant_concerne
    ". احداث قطب قروى داخل الوكالات الحضرية -" reponse
    num_quest "690"
    equipe_concernee "none"
    "اتكارت طارق" representant_concerne
    ".إعطاء الانطلاقة لبرنامج متطوع يهم فئة الشباب الذين تتراوح أعمارهم ما بين 18 و22 سنة -"
    num_quest "7626"
▼ 3
    "فريق الأصالة و المعاصرة" equipe_concernee
    representant_concerne 'احمد تويزي''
    ".|عطاء الانطلاقة لبرنامج متطوع يهم فئة الشباب الذين تتراوح أعمارهم ما بين 18 و22 سنة -"
    num_quest "7621"
4
    "فريق الأصالة و المعاصرة" equipe_concernee
    "احمد تويزي" representant_concerne"
    ".تعديل القانون رقم 28.00 المتعلق بتدبير النفايات والتخلص منها -" reponse
    num auest "6658"
```

Figure 5: Les engagements

3. Stockage et Modules de Traitement :

3.1. **Espace de Staging :** Temporairement, les données brutes sont stockées ici après leur extraction.



Figure 6: Cloudera

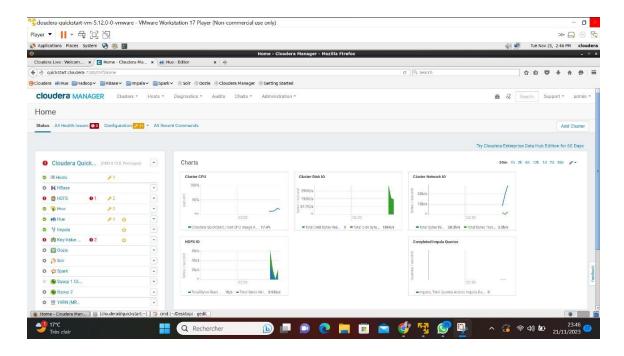


Figure 7: Cloudera manager

3.2. **Raw Area:** nous avons effectué l'anonymisation, la préparation et le nettoyage des données. Les données ainsi traitées ont été transférées dans HDFS pour l'étape suivante.

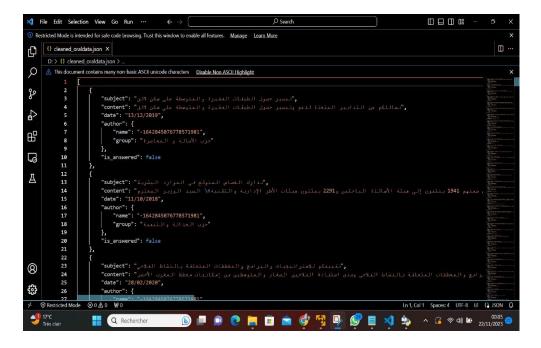


Figure 8: Data Anonymise

```
[cloudera@quickstart ~]$ hadoop fs -copyFromLocal /home/cloudera/Desktop/BigData/oral.txt hdfs:///user/cloudera/RawArea/
[cloudera@quickstart ~]$ hadoop fs -copyFromLocal /home/cloudera/Desktop/BigData/ecrit.txt hdfs:///user/cloudera/RawArea/
[cloudera@quickstart ~] hadoop fs -chmod 777 hdfs:///user/cloudera/RawArea/oral.txt
[cloudera@quickstart ~]$ hadoop fs -chmod 777 hdfs:///user/cloudera/RawArea/ecrit.txt
[cloudera@quickstart ~] hadoop fs -ls hdfs:///user/cloudera/RawArea/
Found 3 items
                                32664877 2023-11-15 08:01 hdfs:///user/cloudera/RawArea/cleaned written data.csv
-rwxrwxrwx 1 cloudera impala
                                32620299 2023-11-21 13:21 hdfs:///user/cloudera/RawArea/ecrit.txt
- rwxrwxrwx
           1 cloudera impala
- rwxrwxrwx
           1 cloudera impala
                                10577310 2023-11-21 13:20 hdfs:///user/cloudera/RawArea/oral.txt
[cloudera@quickstart ~]$
📵 Home - Cloudera Man... 📵 cloudera@quickstart:~ 📋 BigData
                                                                           cmd (~/Desktop) - gedit
```

Figure 9: Stockage de la data dans HDSF

- 3.3. **Espace de Travail :** C'est la zone où les données sont nettoyées, normalisées et préparées pour le traitement.
- 3.4. **Espace Business**: Les données transformées et analysées y sont stockées en vue d'une utilisation ultérieure.
- 3.5. **Espace d'Exposition :** Les données prêtes pour la visualisation finale sont stockées ici. Voir chapitre VII (Résultats et Analyse) .
- 4. **Entreposage de données (Hive) :** Ce module assure la création de tables et de schémas dans Hive pour stocker de manière organisée les données traitées.

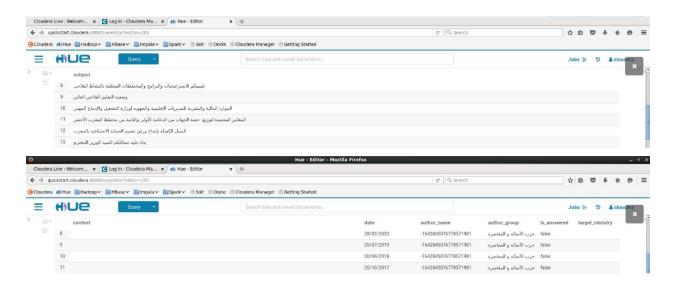


Figure 10: Création des tables dans Hive

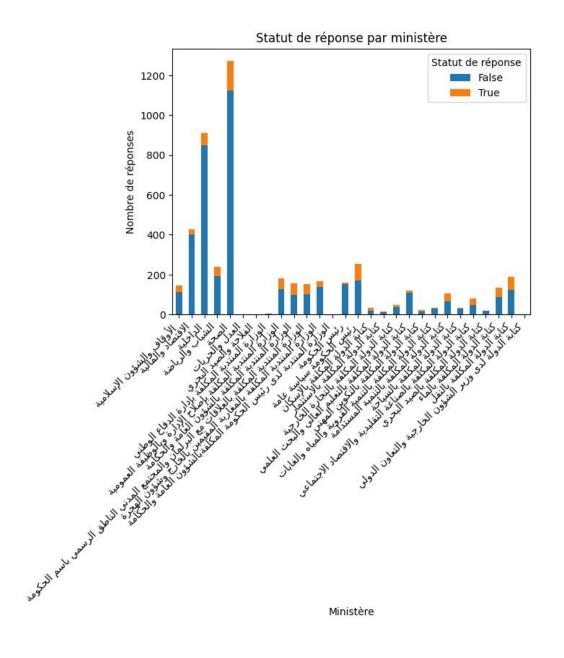
Ces processus de mise en œuvre sont accompagnés de tests approfondis et de validations rigoureuses à chaque étape pour garantir la fiabilité, la qualité et la pertinence des données fournies par la plateforme.

VII - Résultats et Analyse :

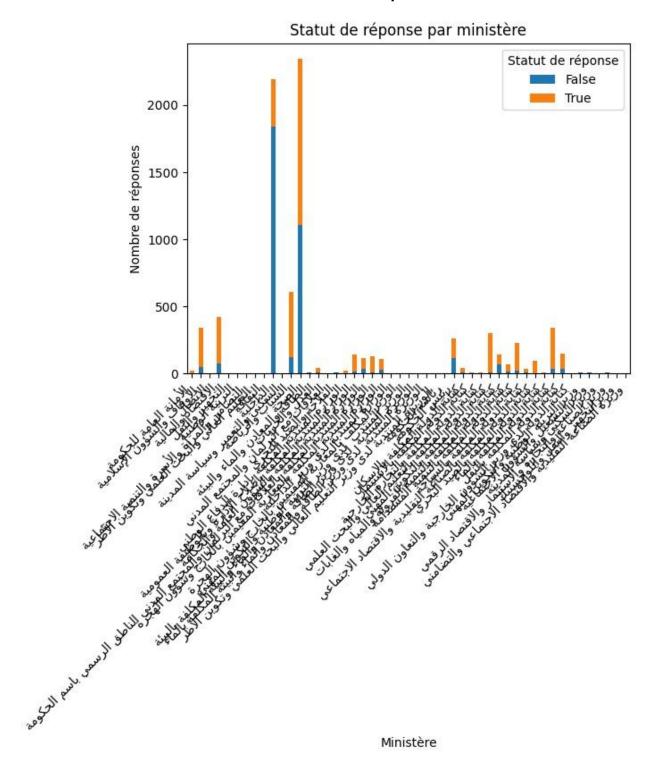
1. Insights tirés des données traitées et visualisées :

La visualisation que nous avons générée représente le nombre de réponses "True" et "False" pour chaque ministère, empilées les unes sur les autres. Chaque barre dans le graphique représente un ministère, et la hauteur de la barre est la somme du nombre de réponses "True" et "False" pour ce ministère.

> Visualisation des données liées aux questions orales :



> Visualisation des données liées aux questions écrites :



2. Interprétation :

- > Axe des X (horizontal) : Les ministères sont représentés sur l'axe horizontal. Chaque barre correspond à un ministère spécifique.
- Axe des Y (vertical): Le nombre total de réponses est représenté sur l'axe vertical. La hauteur de chaque barre représente le nombre total de réponses pour un ministère donné.

Cette visualisation peut aider à comparer la distribution des réponses entre les ministères et à identifier ceux qui ont un nombre élevé de réponses "True" ou "False". Cela peut être utile pour tirer des conclusions sur la performance ou la satisfaction associée à chaque ministère.

VIII - Conclusion:

1. Récapitulation des objectifs atteints :

En récapitulant les objectifs atteints, notre projet a réussi à mettre en place une plateforme Big Data novatrice pour accroître la transparence parlementaire. La pseudonymisation des données sensibles, l'extraction efficace des informations du site web par le biais de scripts de scraping, et la création de modules de stockage, traitement, et visualisation ont constitué des jalons cruciaux. Les processus d'ingénierie des données et d'analyse ont assuré la qualité et la pertinence des informations extraites. Le suivi constant de la plateforme a garanti son bon fonctionnement opérationnel. Les enseignements tirés soulignent l'importance de l'agilité, de la collaboration et de l'adaptabilité dans des projets de cette envergure.

2. Enseignements tirés et perspectives d'avenir :

Quant aux perspectives d'avenir, notre engagement envers l'amélioration continue se manifeste par notre désir d'explorer des moyens d'optimiser l'efficacité de la plateforme. Nous envisageons également d'intégrer des fonctionnalités innovantes et de collaborer avec d'autres acteurs pour élargir l'impact de notre initiative. Forts de notre expérience, nous sommes déterminés à jouer un rôle central dans la promotion de la transparence parlementaire et de l'engagement civique en utilisant des solutions Big Data à la pointe de la technologie. Notre avenir sera façonné par notre engagement envers l'innovation, l'éducation et la contribution continue à l'avancement des technologies de données au service de la société.

IX- Webographie:

- ➤ https://www.chambredesrepresentants.ma/fr/
- ➤ https://fr.wikipedia.org/wiki/Wikip%C3%A9dia:Accueil_principal
- ➤ https://hive.apache.org/

X- Annexes:

➤ Lien vers code complet sur Colab : <u>https://colab.research.google.com/drive/1RNtyyn5WFk1_fJbJLxEdkAJb0Ro6BJ4D?usp=</u> sharing